



上海大学
SHANGHAI UNIVERSITY

本科毕业论文（设计）

UNDERGRADUATE THESIS (PROJECT)

题 目：融合多粒度图神经网络的脑电情绪多
数据集联合预训练方法

学 院：计算机工程与科学

专 业：计算机科学与技术

学 号：22122886

学生姓名：卫祎懿

指导教师：马丽艳

起讫日期：2025 年 12 月起 2026 年 5 月止



姓 名：卫祎懿

学 号：22122886

论文题目：融合多粒度图神经网络的脑电情绪多数据集联合预训练方法

原创性声明

本人声明：所呈交的论文是本人在指导教师指导下进行的研究工作。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已发表或撰写过的研究成果。参与同一工作的其他同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

签 名： Erin Sheng 日 期： 2026.05.11

本论文使用授权说明

本人完全了解上海大学有关保留、使用学位论文的规定，即：学校有权保留论文及送交论文复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容。

（保密的论文在解密后应遵守此规定）

签 名： Erin Sheng 指导教师签名： Erin Sheng 日 期： 2026.05.11

摘 要

脑电图(EEG)情绪识别面临跨受试者泛化能力不足的挑战。mdJPT^[1]提出了一种基于多数据集联合预训练(Multi-dataset Joint Pretraining, mdJPT)的框架,通过MLLA编码器和跨数据集对比学习(CLISA)损失,从多个EEG数据集中学习统一的特征表示。然而,该框架的编码器主要关注时序依赖关系,对EEG电极之间的空间结构——尤其是大脑不同功能脑区之间的多粒度交互关系——建模不足。受MIND-EEG^[2]多粒度集成网络的启发,本文在mdJPT框架的基础上引入多粒度图神经网络(GNN),将60个电极按10-20国际标准划分为七个功能脑区,构建全局、区域内和区域间三层图结构,并采用基于电极空间距离初始化的可学习邻接矩阵和GAT注意力机制进行空间特征交互。实验在SEED-V和SEED-VII数据集上进行预训练,在SEED-V上检验下游情绪分类性能。结果表明,多粒度GNN在所有评估指标上均带来稳定提升(准确率约+1%, AUROC约+1%),高斯噪声增强策略进一步将准确率提升约+2%。此外,本文设计并实现了基于Web的训练可视化系统,支持损失曲线、t-SNE特征嵌入、GNN邻接矩阵等多维度实时监控。

关键词: 脑电情绪识别; 多数据集预训练; 图神经网络; 对比学习; 多粒度空间建模

ABSTRACT

Electroencephalogram (EEG) based emotion recognition suffers from limited cross-subject generalization. The mdJPT framework proposes a multi-dataset joint pretraining approach using MLLA encoder and cross-dataset contrastive learning (CLISA) loss to learn unified feature representations from multiple EEG datasets. However, its encoder focuses primarily on temporal dependencies while inadequately modeling the spatial structure among EEG electrodes—particularly the multi-granularity interactions between different functional brain regions. Inspired by the MIND-EEG multi-granularity integration network, this thesis introduces a multi-granularity graph neural network (GNN) into the mdJPT framework: sixty electrodes are partitioned into seven functional brain regions based on the 10-20 international system, and three-level graph structures (global, intra-region, inter-region) are constructed with learnable adjacency matrices initialized from electrode spatial distances and GAT attention mechanisms for spatial feature interaction. Experiments with pretraining on SEED-V and SEED-VII datasets and downstream evaluation on SEED-V demonstrate that the multi-granularity GNN consistently improves all metrics (accuracy +1%, AUROC +1%), while Gaussian noise augmentation further boosts accuracy by approximately +2%. A web-based training visualization system supporting real-time monitoring of loss curves, t-SNE embeddings, and GNN adjacency matrices is also designed and implemented.

Keywords: EEG emotion recognition; multi-dataset pretraining; graph neural network; contrastive learning; multi-granularity spatial modeling

目 录

摘 要 I

ABSTRACT II

1 绪论 1

1.1 研究背景与意义 1

1.2 国内外研究现状 2

1.2.1 基于深度学习的 EEG 情绪识别 2

1.2.2 多数据集预训练与迁移学习 3

1.2.3 图神经网络与脑区建模 5

1.3 本文研究内容 5

1.4 论文结构 5

1.5 本章小结 6

2 相关工作 7

2.1 EEG 情绪识别数据集 7

2.2 对比学习与 mdJPT 框架 7

2.3 图神经网络在 EEG 中的应用 8

2.4 MLLA 编码器 9

2.4.1 逐通道 Patch Embedding 9

2.4.2 线性注意力机制 9

2.4.3 精简的模型规模 10

2.4.4 与 Transformer 的量化对比 10

2.5 本章小结 10

3 多数据集联合预训练框架 11

3.1 总体架构 11

3.2 通道投影与数据预处理 12

3.2.1 标准电极布局 12

3.2.2 最近邻插值算法 12

3.2.3 预计算的通道插值矩阵 13

3.3 MLLA 时序编码器	13
3.4 多粒度空间 GNN	14
3.4.1 脑区功能分区	14
3.4.2 三层图结构	14
3.4.3 可学习邻接矩阵	14
3.4.4 特征融合	15
3.5 预训练损失函数	15
3.5.1 跨受试者对比采样	15
3.5.2 协方差分布对齐（CDA）	16
3.5.3 向量量化辅助损失（VQ）	16
3.5.4 总损失	16
3.6 特征提取与下游评估	16
3.6.1 逐批内存高效特征提取	17
3.6.2 特征模式选择	17
3.6.3 运行归一化	17
3.6.4 标签分布平滑（LDS）	17
3.6.5 下游 MLP 评估	18
3.7 本章小结	18
4 实验与分析	19
4.1 数据集与实验设置	19
4.2 可学习邻接矩阵的效果	19
4.3 参数敏感性分析	19
4.4 数据增强	20
4.5 GNN 提升与 VQ 退步的机制分析	21
4.6 最佳参数组合	22
4.7 训练可视化系统	23
4.7.1 实时损失曲线	23
4.7.2 GNN 邻接矩阵热力图	24
4.7.3 t-SNE 特征嵌入	25
4.7.4 训练控制与参数配置	25
4.7.5 下游评估可视化	26
4.7.6 系统架构与技术实现	26
4.8 本章小结	27

5 总结与展望 28

 5.1 全文总结 28

 5.2 未来展望 28

结论 30

参考文献 31

附录 A 附录：实验参数配置 33

附录 B 附录：数据集详情 34

致 谢 35

1 绪论

1.1 研究背景与意义

情绪是人类认知和行为的重要组成部分，准确识别情绪状态在众多领域具有广泛的应用前景和迫切的社会需求：

- **心理健康监测与干预：**世界卫生组织数据显示，全球约有 3.5 亿抑郁症患者，情绪障碍的早期筛查和持续监测对疾病预防具有重要意义。基于 EEG 的客观情绪评估可辅助临床诊断，减少主观问卷的偏差，实现对患者情绪状态的连续、无创追踪。
- **疲劳驾驶预警与交通安全：**驾驶员情绪状态（如愤怒、焦虑、疲劳）是交通事故的重要诱因。基于脑电的实时情绪监测可集成至车载系统，在检测到驾驶员情绪异常时触发预警或接管机制。相比基于面部表情或驾驶行为的方案，EEG 信号能更早地捕捉到认知状态的微妙变化。
- **智能教育与自适应学习：**学习者的情绪状态（困惑、投入、无聊）直接影响学习效果。基于 EEG 的实时情绪反馈可使智能教学系统动态调整教学策略（如降低难度、切换讲解方式），实现真正的个性化自适应学习。这一方向在教育信息化和元宇宙教育场景中展现出巨大潜力。
- **人机交互与情感计算：**随着 AI 助手、社交机器人、虚拟现实等技术的普及，机器对人类情绪的感知与响应能力成为用户体验的关键。脑机接口（BCI）作为最直接的神经交互通道，能够绕过面部表情和社会掩饰行为，获取真实的内部情绪状态，为下一代情感智能交互提供核心技术支持。

脑电图（EEG）作为一种非侵入式、高时间分辨率（毫秒级）的神经生理信号，能够直接反映大脑皮层神经元群的同步电活动，是情绪识别研究中不可替代的核心模态。与面部表情分析、语音情感识别等外周信号相比，EEG 具有以下独特优势：（1）直接反映中枢神经系统的情绪加工过程，不受主观伪装的影响；（2）毫秒级的时间分辨率能够捕捉情绪的瞬时动态变化；（3）在光照条件差、面部遮挡等复杂环境下仍可稳定工作。然而，EEG 信号也存在信噪比低、个体差异大、空间分辨率有限等固有挑战，使得跨受试者泛化成为 EEG 情绪识别走向实际应用的核心瓶颈。

在跨受试者泛化问题上，不同个体的 EEG 信号分布存在显著差异——受年龄、性别、颅骨厚度、疲劳程度、甚至饮食习惯等因素影响，在源受试者上训练的模型直接

应用于新受试者时性能通常急剧下降。为缓解这一问题，研究者们探索了多种技术路线：McdPL^[3] 采用成对学习优化框架和无监督域对抗训练，通过三步对抗策略显式处理决策边界附近的争议样本；MATL-DC^[4] 提出多域聚合迁移学习方法，通过最大均值差异（MMD）计算受试者间分布距离，采用基于 MMD 的 K-means++ 将相似受试者聚合为超域，实现零样本跨被试泛化；^[5] 使用双分支深度学习架构融合 CNN 和 RNN 特征，通过显著性引导机制增强跨模态互补性；^[6] 设计了面向消费级脑电设备的轻量化多尺度时间卷积方法，在便携式设备上验证了跨设备迁移的可行性。

在多数据集联合利用方面，现有 EEG 情绪数据集（如 SEED 系列、DEAP、AMIGOS 等）各自采集标准不一、电极布局不同、情绪类别体系各异，单一数据集训练难以获得泛化能力强的模型。mdJPT^[1] 提出了基于多数据集联合预训练的框架（Multi-dataset Joint Pretraining, mdJPT），以 MLLA 编码器进行逐通道时序建模，通过跨数据集对比学习（CLISA）和协方差分布对齐（CDA）损失，从多个 EEG 数据集中学习统一的特征表示。该框架在 SEED-VII 和 SEED-V 上进行联合预训练后，在 SEED-V 下游分类任务上取得了优于单数据集训练的性能，验证了多数据集预训练在 EEG 情绪识别领域的有效性。然而，mdJPT 的 MLLA 编码器主要关注 EEG 信号的时序依赖关系，对电极之间的空间结构——特别是大脑不同功能脑区之间的多粒度交互关系——建模不足。

为弥补这一不足，本文受 MIND-EEG^[2] 多粒度集成网络的启发，在 mdJPT 框架的基础上引入多粒度图神经网络（GNN）进行脑区空间建模。MIND-EEG 提出将脑区划分为全局、区域内和区域间三个粒度层次，分别用图神经网络建模后融合，并通过离散码本防止过平滑，在多个数据集上验证了多粒度建模的有效性。本文借鉴其多粒度分区思想，将 60 个电极按 10-20 国际标准划分为七个功能脑区，构建三层图结构并采用基于电极空间距离初始化的可学习邻接矩阵和 GAT 注意力机制进行空间交互。此外，本文对框架的关键超参数进行了系统性调优实验，探索了数据增强策略对模型鲁棒性的影响，并设计实现了基于 Web 的训练可视化系统。

1.2 国内外研究现状

1.2.1 基于深度学习的 EEG 情绪识别

EEG 情绪识别的研究经历了从手工特征到深度学习、从单受试者到跨受试者、从单数据集到多数据集的逐步演进。

传统方法阶段（2015年前后）：早期研究主要依赖手工设计的 EEG 特征。Zheng 等人^[7] 系统性地研究了不同频段和电极通道对情绪识别的影响，发现 Gamma 频段和额叶-颞叶区域对情绪具有最强的判别力。差分熵（Differential Entropy, DE）被证明是最有效的 EEG 情绪特征之一，其在五个频段（ δ : 1-4Hz, θ : 4-8Hz, α : 8-14Hz, β : 14-30Hz, γ : 30-47Hz）上的 DE 特征成为后续研究的标配。然而，手工特征依赖领域知识，设计周期长，且泛化能力有限。

深度学习阶段（2018-2022 年）：随着深度学习在计算机视觉和自然语言处理领域的成功，研究者开始将 CNN、RNN、GNN 等架构引入 EEG 情绪识别。TSception^[8] 提出了面向 EEG 的多尺度时间卷积与不对称空间核，通过多个时间尺度的卷积核捕捉不同频率的 EEG 节律，同时使用不对称空间核分别处理左右半球的 EEG 信号，贴合 EEG 的神经生理学特性。DGCNN^[9] 将 EEG 通道建模为动态图结构，利用图卷积网络捕捉电极间的空间依赖关系，其邻接矩阵根据每层特征动态更新，使图结构能够自适应地反映不同情绪状态下的脑网络重组。RGNN^[10] 引入正则化图神经网络，通过对邻接矩阵施加稀疏性和平滑性约束来提高跨受试者的泛化能力，减少了过拟合风险。^[5] 采用双分支深度学习架构——一支 CNN 处理图像化的 EEG 拓扑图，一支层次化 RNN 按电极→脑区→半球逐步聚合特征——然后通过 RNN 的显著性图对 CNN 特征进行加权融合，实现互补模态的协同。^[6] 针对消费级脑电设备通道数少、信噪比低的特点，提出了轻量化的多尺度时间卷积与不对称空间核方法，在 14-32 通道的商用设备上取得了与实验室级设备接近的性能，推动了 EEG 情绪识别从实验室走向日常应用。

Transformer 与预训练阶段（2023 年至今）：Transformer^[11] 架构凭借自注意力机制捕捉长程依赖关系的能力，也被广泛应用于 EEG 时序建模。研究者探索了将 EEG 信号划分为时间 patch 后输入 Transformer 的范式，以及基于掩码自编码器（MAE）的自监督预训练方法。然而，标准 Transformer 的自注意力复杂度为 $O(N^2)$ ，在处理高采样率的长序列 EEG 信号时面临计算瓶颈，这为高效注意力机制（如 MLLA 的线性注意力）的引入提供了直接动机。

1.2.2 多数据集预训练与迁移学习

对比学习在自监督表示学习领域取得了突破性进展，其核心理念——通过最大化同一数据的不同增强视图之间的一致性来学习特征表示——已被证明能够从无标签数据中提取高质量的通用特征。SimCLR^[12] 通过简单的数据增强（随机裁剪、颜色抖动等）和大量的负样本对比，在 ImageNet 上达到了与有监督学习相当的性能。MoCo^[13]

引入动量编码器和动态队列字典，解耦了批量大小与负样本数量的约束，使大规模对比学习成为可能。这些方法为 EEG 领域的跨数据集预训练提供了方法论基础。

在跨被试迁移学习方面，域自适应和域泛化是两条主要的技术路线。域自适应方法（如 DANN）通过梯度反转层（GRL）对齐源域和目标域的特征分布，但通常要求目标域数据参与训练，且全局对齐容易混淆不同类别的边界样本。域泛化方法则追求在未见过的目标域上直接泛化，更具实用价值。

McdPL^[3] 提出了无监督成对学习优化框架，将传统的一步域对抗扩展为三步训练：（1）基础训练——使用源域数据训练特征提取器和两个异构分类器（分别用 Adam 和 RMSprop 优化，使两个分类器具有不同的决策边界偏好）；（2）最大化分类器差异——固定特征提取器，训练两个分类器使它们对目标域样本的预测差异最大化，差异最大的样本即为靠近决策边界的“争议样本”；（3）最小化特征分布差异——固定分类器，训练特征提取器将目标域特征向源域聚类中心靠拢。McdPL 实验表明，在源域标签噪声达 30% 时，成对学习策略的性能下降仅 3.32%，而传统点式学习下降 6.69%。

MATL-DC^[4] 提出多域聚合迁移学习方法，将每个受试者视为独立域，通过基于高斯核 MMD 的最大均值差异计算受试者间的分布距离，采用 MMD-based K-means++ 将相似受试者聚合为 K 个超域。在每个超域内学习域原型，在全局学习类原型，推理时新受试者先匹配到最近超域再使用该类原型分类，实现真正的零样本跨被试泛化。

mdJPT^[1] 提出了专门面向多 EEG 数据集场景的联合预训练框架。其核心设计包括：（1）MLLA 编码器——以线性复杂度处理多通道长序列 EEG 信号；（2）CLISA 对比学习——利用不同数据集受试者观看相同视频的独特采集范式，将不同数据集、同一视频下的样本对作为跨域正样本对；（3）CDA 损失——通过对齐各数据集通道协方差矩阵的结构来减少域间差异；（4）VQ 码本——对特征协方差进行向量量化，提供隐式的特征空间正则化。mdJPT 在 SEED-V 和 SEED-VII 上的联合预训练实验证明了多数据集预训练相比单数据集训练在下游分类任务上的显著优势，模型参数量仅约 75 万，单 epoch 训练仅需数秒。^[14] 则从另一个角度探索了基于预训练视觉模型（迁移 ImageNet 预训练 CNN 到 EEG 拓扑图）的跨数据集 EEG 情绪识别方法。

然而，现有跨数据集预训练方法主要关注时序建模（通过 MLLA/Transformer 捕捉 EEG 的时间动态），对电极之间的空间结构——尤其是不同功能脑区之间的多粒度交互关系——的利用尚不充分。这一研究空白为本文的多粒度 GNN 改进提供了直接的研究动机。

1.2.3 图神经网络与脑区建模

图神经网络（GNN）^[15] 通过消息传递机制在非欧几里得结构数据上学习节点表示。图注意力网络（GAT）^[16] 引入注意力机制自适应学习节点间的权重。在 EEG 分析中, GNN 已被应用于将电极建模为图节点、捕捉脑区内部和脑区之间的功能连接关系^[17]。MIND-EEG^[2] 进一步提出了多粒度集成网络, 将脑区划分为全局、区域内和区域间三个粒度层次分别建模, 并通过离散码本对动态图结构进行向量量化以防止过平滑。然而, MIND-EEG 的三个粒度编码器结构较为复杂, 且针对单数据集场景设计。本文借鉴其多粒度分区思想, 在 mdJPT 多数据集预训练框架中引入简化但有效的三层图结构（全局-区域内-区域间）, 并采用基于电极空间距离初始化的可学习邻接矩阵替代固定或全连接邻接矩阵。

1.3 本文研究内容

本文在 mdJPT^[1] 多数据集联合预训练框架的基础上, 受 MIND-EEG^[2] 多粒度集成网络的启发, 进行以下三方面的工作:

- (1) **多粒度空间 GNN 模块设计:** 将 10-20 国际标准下的 60 导联划分为七个功能脑区（前额叶、额叶、额中央、中央、颞叶、顶叶、枕叶）, 构建三层图结构——全局全连接图、区域内全连接图、区域间交互图。在每个层级使用基于电极空间距离初始化的可学习邻接矩阵和 GAT 动态注意力机制, 替代传统的固定全连接邻接矩阵。
- (2) **超参数调优与数据增强探索:** 在 mdJPT 框架内系统性地探索学习率、CLISA 温度、CDA 因子、VQ 权重、编码器深度等关键参数对预训练质量的影响, 发现 CLISA 温度（0.2）和学习率（ $1e-3$ ）为最敏感参数, 并验证了轻微高斯噪声增强（ $\sigma = 0.005$ ）能有效提升模型鲁棒性。
- (3) **训练可视化系统设计与实现:** 开发基于 FastAPI 后端和 Chart.js 前端的实时训练监控 Web 界面, 支持损失曲线、t-SNE 特征嵌入、GNN 邻接矩阵热力图、混淆矩阵、ROC 曲线、逐受试者性能热力图等多维度可视化。集成参数配置面板, 可将 config_multi.yaml 中的全部超参数通过 Web 界面可视化编辑, 并一键应用至训练, 支持远程启停训练和特征提取。

1.4 论文结构

本文共分为五章, 结构安排如下:

- **第一章：绪论。**介绍研究背景、国内外研究现状、主要贡献和论文结构。
- **第二章：相关工作。**综述 EEG 情绪识别、多数据集预训练和图神经网络的相关技术。
- **第三章：方法。**详细阐述 MLLA 编码器、多粒度 GNN、联合预训练框架和下游评估的完整技术方案。
- **第四章：实验与分析。**介绍数据集、实验设置, 展示消融实验和参数对比结果, 并介绍可视化系统。
- **第五章：总结与展望。**总结全文工作并展望未来改进方向。

1.5 本章小结

本章介绍了 EEG 情绪识别的研究背景和实际应用价值, 分析了跨受试者泛化和多数据集利用两大核心挑战。在综述国内外研究现状的基础上, 明确了本文的多粒度 GNN 建模、多数据集联合预训练和训练可视化三大研究方向, 并概述了本文的主要贡献和章节安排。

2 相关工作

2.1 EEG 情绪识别数据集

近年来, 多个公开的 EEG 情绪数据集为深度学习方法的验证提供了基础, 本文主要使用以下三个基于 SEED (SJTU Emotion EEG Dataset) 系列的数据集:

- **SEED-V**^[18] (SJTU Emotion EEG Dataset-V): 包含 16 名受试者 (男女各 8 名), 使用 62 通道 ESI NeuroScan 系统以 1000Hz 采样后降采样至 125Hz, 覆盖 60 个 10-20 标准电极。每位受试者观看 15 个精心选取的电影片段 (每个约 4 分钟), 分别诱发 5 种目标情绪: 中性 (neutral)、悲伤 (sad)、恐惧 (fear)、快乐 (happy)、厌恶 (disgust)。实验共分为 3 个 session, 不同 session 之间间隔至少一周, 以涵盖受试者不同生理状态下的 EEG 信号。预处理流程包括: 0.5-47Hz 带通滤波以去除直流漂移和高频噪声、ICA 独立成分分析自动去除眼电和肌电伪迹。单个 EEG 样本以 5 秒滑动窗口 (步长 2 秒) 切分, 得到 60 times 625 的二维数据 (60 通道×625 时间点)。
- **SEED-VII**: 包含 19 名受试者, 62 通道 EEG 数据, 采样率 125Hz。该数据集使用 20 个电影片段诱发 7 种情绪类别 (中性、悲伤、恐惧、快乐、厌恶、惊讶、愤怒), 相比 SEED-V 的五分类体系更为细粒度。每位受试者参与 4 个 session (间隔至少一周), 数据预处理流程与 SEED-V 一致 (0.5-47Hz 滤波、ICA 去伪迹)。每样本以 5 秒窗口 (步长 2 秒) 切分, 统一投影至 60 通道标准空间。SEED-VII 的更多情绪类别和更多受试者使其成为预训练的理想数据集, 为模型提供了更丰富的情绪特征先验。
- **SEED-IV**: 包含 15 名受试者, 62 通道 EEG 数据, 4 种情绪类别 (中性、悲伤、恐惧、快乐), 每位受试者参与 3 个 session, 每个 session 包含 24 个视频片段。采样率 125Hz, 预处理流程同上。SEED-IV 将作为未来扩展纳入联合预训练的数据集中, 以进一步验证框架在多数据集场景下的可扩展性。

以上三个数据集均基于 10-20 国际标准电极布局。在 mdJPT 框架中, 所有数据集经过统一的通道投影操作——定义包含 60 个标准电极的固定布局, 缺失通道通过最近邻电极的线性插值填充, 多余通道丢弃——从而将不同电极布局的数据集统一映射至相同维度的特征空间。数据集概览如附录表 B1 所示。

2.2 对比学习与 mdJPT 框架

SimCLR^[12] 通过在特征空间中对正样本对拉近、负样本对推远的方式进行自监督学习, 其核心是 InfoNCE 损失函数。mdJPT^[1] 在此基础上提出 CLISA (Contrastive Learning with Intra-Subject Augmentation) 损失, 针对 EEG 数据的特性设计了跨数据集的正负样本对构造策略: 不同数据集、同一 session、不同受试者、相同视频刺激下的 EEG 片段作为正样本对, 其余为负样本。同时, mdJPT 引入协方差分布对齐 (CDA) 损失与向量量化 (VQ) 损失, 通过对齐各数据集通道协方差矩阵和特征空间量化来增强跨数据集特征对齐。本文完整复现了 mdJPT 框架并在其上进行了 GNN 改进和参数调优实验。

2.3 图神经网络在 EEG 中的应用

图卷积网络 (GCN)^[15] 通过消息传递机制在非欧几里得结构数据上学习节点表示, 其核心操作是聚合邻居节点的特征来更新每个节点的表示: 依次聚合邻居节点的特征, 通过可学习的权重矩阵对邻域信息进行线性变换和非线性激活, 从而更新每个节点的表示。在 EEG 分析中, 将每个电极视为图节点、电极间的功能连接或空间距离编码为边的权重, 可构建图结构进行情绪分类。

图注意力网络 (GAT)^[16] 在 GCN 的基础上引入注意力机制, 为不同邻居分配不同的重要性权重。注意力系数通过可学习的注意力向量 $\mathbf{a}$ 和权重矩阵 $\mathbf{W}$ 计算, 对邻居节点的特征进行加权聚合。本文采用的 GAT 机制的独特之处在于: 注意力权重计算不仅基于节点特征的拼接, 还受可学习邻接矩阵 $\mathbf{A}$ 的调制——最终边权重为注意力权重与邻接矩阵值的乘积, 使注意力在遵循空间距离先验的基础上进行自适应调整。

在 EEG 情绪识别中, GNN 已被应用于将电极建模为图节点、捕捉脑区内部和脑区之间的功能连接关系^[17]。MIND-EEG^[2] 进一步提出了多粒度集成网络, 将脑区划分为全局、区域内和区域间三个粒度层次分别建模, 并通过离散码本对动态图结构进行向量量化以防止过平滑。然而, MIND-EEG 的三个粒度编码器结构较为复杂, 且针对单数据集场景设计。

DGCNN^[9] 使用动态图卷积网络, 根据每层特征动态更新邻接矩阵。RGNN^[10] 通过正则化邻接矩阵提高跨受试者泛化能力。这些方法均在不同层面探索了图结构在 EEG 空间建模中的应用。

本文借鉴 MIND-EEG 的多粒度分区思想, 在 mdJPT 多数据集预训练框架中引入简化但有效的三层图结构 (全局-区域内-区域间), 并采用基于电极空间距离初始化的

可学习邻接矩阵替代固定或全连接邻接矩阵。与现有 GNN 方法的本质不同在于：（1）邻接矩阵不是完全自由的参数, 而是从 10-20 空间距离的高斯核初始化, 为模型提供了具有神经生理学意义的归纳偏置；（2）GNN 以残差方式作用于 MLLA 的时序输出, 而非替代时序编码；（3）GNN 在预训练阶段与 CLISA 目标端到端联合优化。

2.4 MLLA 编码器

多尺度局部线性注意力（Multi-scale Local Linear Attention, MLLA）是 mdJPT 框架的核心时序编码器, 也是其轻量化设计的关键所在。MLLA 的设计遵循“逐通道 Patch 化→线性注意力→特征投影”的三阶段流水线, 以极低的参数和计算开销捕捉 EEG 信号的时序依赖关系。

2.4.1 逐通道 Patch Embedding

MLLA 首先将每个 EEG 通道视为独立的时序序列进行处理。给定输入 $\text{boldx} \in \mathbb{R}^{B \times T \times C}$ （其中 $C = 60$ 为通道数, $T = 625$ 为 5 秒 $\times 125\text{Hz}$ 的时间点数）, MLLA 以步长 $S = 6$ 、窗口大小 $P = 32$ 将每个通道划分为 $N = \lfloor (625-32)/6 \rfloor + 1 = 99$ 个 patch。每个 patch 包含 32 个连续采样点的原始 EEG 幅值, 构成一个 32 维的 token。这一操作将 $B \times 60$ 个独立的时序序列转换为 $(B \times 60) \times 99 \times 32$ 的 token 序列, 整个过程无额外可学习参数。

2.4.2 线性注意力机制

这是 MLLA 轻量化的核心。标准 Transformer 的自注意力机制需要计算每两个 token 之间的相似度, 形成 $N \times N$ 的注意力矩阵, 计算复杂度为 $O(N^2)$ 。对于 $N = 99$ 个 patch, 每个通道需要计算 $99^2 = 9801$ 次成对交互；当 60 个通道、2 层堆叠时, 单个样本的注意力计算量达到 $60 \times 2 \times 9801 \approx 1.18 \times 10^6$ 量级。

MLLA 采用的线性注意力通过特征映射 $\text{ELU}(x)+1$ 将计算过程重新组织。其核心数学原理为：利用矩阵乘法的结合律, 将 $\text{softmax}(QK^T V)$ 替换为 $\phi(Q)(\phi(K)^T V)$ 。先计算 $\phi(K)^T V$ （一个 $d \times d$ 的矩阵, 与序列长度 N 无关）, 再右乘 $\phi(Q)$ 。这一重排将复杂度从 $O(N^2 d)$ 降至 $O(N d^2)$, 其中 $d=32$ 为特征维度。因为 $d=32 \ll N=99$, 实际的加速效果显著——每个通道的注意力计算量从 9801 次成对交互骤降至约 99 次, 理论加速比接近 100 倍。同时, MLLA 还引入了 RoPE（旋转位置编码）为序列注入相对

位置信息, 以及 LePE（局部增强位置编码）通过深度可分离卷积捕获局部上下文, 增强了对 EEG 时序模式的建模能力。

2.4.3 精简的模型规模

MLLA BasicLayer 由 $D = 2$ 层 MLLA EncoderLayer 堆叠而成。每层包含线性注意力模块和两层 FFN（前馈网络, 隐藏维度 256、GELU 激活）。编码器的输入先通过线性投影从 patch 维度（32）映射到隐藏维度（128）, 经过 2 层编码后, 再通过输出投影映射到 $D_{out}=32$ 维。整个 MLLA 编码器仅约 37.5 万参数。

值得注意的是, MLLA 对所有 60 个通道复用同一套编码器参数——将 B times 60 个通道的序列展平后批处理——参数量与通道数完全解耦。这一设计使得无论输入多少通道的 EEG 数据, MLLA 编码器的大小都保持不变, 避免了传统方法中参数随通道数线性增长的问题。

2.4.4 与 Transformer 的量化对比

表 2.1 展示了 MLLA 线性注意力与标准 Transformer 自注意力在关键指标上的对比。

表 2.1 MLLA 与标准 Transformer 的轻量化对比

指标	标准 Transformer	MLLA（本文）	加速比
注意力复杂度	$O(N^2)$	$O(N)$	100times
每通道交互次数（ $N=99$ ）	9801	99	99times
编码器参数量	200 万+（常见规模）	37.5 万	5.3times 更小
通道数影响	参数随通道数线性增长	参数与通道数解耦	—

综上所述, MLLA 通过三项关键设计实现了轻量化: 线性注意力降低计算复杂度、小维度输出压缩参数量、逐通道共享权重将参数量与通道数解耦。这三者协同作用, 使 mdJPT 框架在 SEED-VII（19 受试者 $\times$ 4 session、约 13 万条训练样本）上的单 epoch 训练仅需约 6-7 秒, 显著快于同期基于标准 Transformer 的 EEG 预训练方法。

2.5 本章小结

本章介绍了本文工作所依赖的关键技术基础: SEED 系列 EEG 数据集、对比学习与 CLISA 损失、图神经网络在 EEG 中的应用以及 MLLA 编码器架构。这些技术共同构成了后文多数据集联合预训练框架的基础。

3 多数据集联合预训练框架

3.1 总体架构

本文的工作基于 mdJPT^[1] 的多数据集联合预训练框架, 在其基础上引入多粒度空间 GNN 模块。整体架构由以下四个模块组成:

- (1) **MLLA 时序编码器** (mdJPT 基础模块): 对每个 EEG 通道独立进行 patch-level 时序建模, 提取时序依赖关系
- (2) **多粒度空间 GNN** (本文改进模块): 在时序表示的基础上实现脑区功能分区间的空间交互
- (3) **CNN 投影头** (mdJPT 基础模块): 将空间-时序特征投影为对比学习所需的 CLISA 表示
- (4) **下游 MLP 评估** (mdJPT 基础模块): 在预训练完成后提取特征并训练轻量分类器

框架的训练流程如下图所示。预训练阶段在多个数据集上联合优化 CLISA 损失和 CDA 损失, 特征提取阶段将预训练编码器作为固定特征提取器, MLP 评估阶段在目标数据集上进行跨受试者情绪分类。

mdJPT 框架的一个显著特点是其轻量化设计, 使其在多个数据集联合预训练场景下仍能保持较高的训练效率。这一特性主要源于三个方面:

- (1) **线性注意力机制**: MLLA 编码器采用基于 ELU+1 特征映射的线性注意力 (Linear Attention), 将标准 Transformer 的自注意力计算复杂度从 $O(N^2)$ 降至 $O(N)$ 。对于每个通道产生的 99 个 patch 序列, 线性注意力仅需约 99 次交互计算, 而标准自注意力需要 $99^2 \approx 9800$ 次——理论加速比接近 100 倍, 当 60 个通道、2 层深度联合作用时, 这一差距被急剧放大。
- (2) **小参数规模**: 整个 mdJPT 编码器 (不含本文新增的 GNN 模块) 仅约 75 万参数。MLLA 编码器的输出维度仅为 32 (远小于常见的 128 或 256 维), 仅堆叠 2 层, CNN 投影头全部采用深度可分离卷积 (Depthwise Convolution), 进一步压缩了参数量和计算量。作为对比, 同期基于标准 Transformer 的 EEG 模型通常达到 200 万参数以上。




图 3.1 多数据集联合预训练框架总体架构

- (3) **逐通道共享权重**: MLLA 编码器对所有 60 个电极通道复用同一套模型参数, 将 $B \times 60$ 个通道的时序序列并行批处理, 参数量与通道数解耦, 避免了为每个通道单独建模的参数膨胀问题。

3.2 通道投影与数据预处理

不同 EEG 数据集的电极布局存在差异, 难以直接混合训练。例如, SEED-V 使用 60 个 10-20 电极, SEED-VII 使用 62 个, 而 DEAP 仅含 32 个。mdJPT 框架通过统一的通道投影 (Channel Projection) 操作将所有数据集映射到同一标准空间, 消除跨数据集的维度差异。

3.2.1 标准电极布局

本文定义了一套包含 60 个标准 10-20 系统电极的固定布局 (涵盖前额叶/额叶/额中央/中央/颞叶/顶叶/枕叶的完整覆盖), 作为所有数据集的统一目标空间。这些电极从额极 (FP1、FPZ、FP2) 至枕区 (O1、OZ、O2) 完整覆盖了大脑的头皮表面, 与 3.3 节的 7 个功能脑区划分完全一致。

3.2.2 最近邻插值算法

对于每个数据集, 根据其实际电极列表与标准布局的对应关系, 采用以下三种情况进行处理:

- (1) **直接映射**: 若数据集电极与标准电极名称一致（不区分大小写），直接将信号复制到对应位置。
- (2) **最近邻插值**: 若标准电极在数据集中缺失，通过预计算的通道插值矩阵（“channel_interpolate.npy”）查找该电极在标准布局中的 3 个最近邻电极，取这些电极信号在数据集中的均值作为插值结果。插值矩阵基于 10-20 电极的 2D 空间坐标 $((x,y))$ 归一化至 $[-1,1]$ 范围）计算欧氏距离最近邻。
- (3) **通道丢弃**: 若数据集中存在标准布局之外的额外电极，直接丢弃。

投影后的数据统一表示为四维张量 $\text{boldX in } \mathbb{R}^{B \times 1 \times C \times T}$, 其中 B 为批量大小, $C = 60$ 为统一通道数, $T = 625$ 为 5 秒窗口在 125Hz 采样率下对应的时间点数。这一预处理在数据加载阶段完成, 不增加训练时的计算开销。

3.2.3 预计算的通道插值矩阵

通道插值矩阵在训练前预计算并存储为 NumPy 数组, 避免了每次数据加载时的重复计算。矩阵 $\text{boldM in } \mathbb{R}^{60 \times K}$ 的每一行对应一个标准电极的 K 个最近邻电极索引（按距离升序排列, 默认 $K = 3$ ）。对于数据集中完全不存在的偏远电极（如个别受试者中 TP7 无信号）, 插值退化为取可用最近邻的均值；若全部 K 个最近邻均不可用, 则用零填充。这一机制确保了通道投影在任何数据配置下均能鲁棒运行。

3.3 MLLA 时序编码器

本文在 mdJPT 框架中复现的 MLLA 编码器沿用 2.4 节所述的架构设计, 并验证了其轻量化特性。编码器以逐通道方式处理 EEG 信号: 给定输入 $\text{boldx in } \mathbb{R}^{B \times 1 \times C \times T}$, 首先将每个通道视为独立的时序序列, 通过 patch embedding 将长度为 T 的序列切分为 $N = \text{floor}((T-P)/S) + 1$ 个长度为 P 的 patch, 其中 $P = 32$ 为 patch 大小, $S = 6$ 为步长, 得到 $N = 99$ 个 patch。设通道数为 $C = 60$, 将 $B \times C$ 个通道展平后批量送入 MLLA BasicLayer。

MLLA BasicLayer 由 $D = 2$ 层 MLLA EncoderLayer 堆叠而成。每层包含: CPE（卷积位置编码, 通过深度可分离卷积注入位置信息）、线性注意力（通过特征映射 $\text{ELU}(x)+1$ 实现 $O(N)$ 复杂度的自注意力, 详见 2.4 节分析）和 FFN（两层 MLP 前馈网络, 隐藏维度 256, GELU 激活）。编码器输出形状为 $B \times C \times N \times D_{\text{out}}$, 其中 $D_{\text{out}}=32$, 仅约 37.5 万参数。得益于线性注意力与逐通道共享权重的协同作用, 在整个预训练 pipeline

中, MLLA 编码器并非瓶颈模块——实际训练中单 epoch (SEED-VII, 约 13 万样本, $n_pairs=128$) 仅需约 12 秒。

3.4 多粒度空间 GNN

3.4.1 脑区功能分区

基于 10-20 国际标准, 将 60 个电极按照解剖功能划分为 7 个脑区:

表 3.1 脑区功能分区定义

脑区	电极名称	通道数
前额叶 (PFC)	FP1, FPZ, FP2	3
额叶 (Frontal)	AF3, AF4, F7, F5, F3, F1, FZ, F2, F4, F6, F8	11
额中央 (Fronto-Central)	FC5, FC3, FC1, FCZ, FC2, FC4, FC6	7
中央 (Central)	C5, C3, C1, CZ, C2, C4, C6	7
颞叶 (Temporal)	FT7, FT8, T7, T8, TP7, TP8	6
顶叶 (Parietal)	CP5, CP3, CP1, CPZ, CP2, CP4, CP6, P7, P5, P3, P1, PZ, P2, P4, P6, P8	16
枕叶 (Occipital)	PO7, PO5, PO3, POZ, PO4, PO6, PO8, O1, OZ, O2	10

3.4.2 三层图结构

在每个脑区划分的基础上, 构建以下三层图结构:

- (1) **全局图 (Global Graph)**: 将 60 个电极全部连接为全连接图, 使用可学习邻接矩阵 $\text{boldA_g} \in \mathbb{R}^{60 \times 60}$ 建模全局的电极间空间依赖关系。邻接矩阵通过 softmax 归一化确保行和为 1, 并通过图注意力机制 (GAT) 动态计算边权重。
- (2) **区域内图 (Intra-Region Graph)**: 在每个脑区内部构建子图, 区域内电极相互连接, 使用共享参数的图卷积层提取区域内的局部空间特征, 并通过均值池化得到每个脑区的表示向量。
- (3) **区域间图 (Inter-Region Graph)**: 将 7 个脑区作为超节点, 使用可学习邻接矩阵 $\text{boldA_r} \in \mathbb{R}^{7 \times 7}$ 建模脑区之间的信息交互。

3.4.3 可学习邻接矩阵

与传统的固定邻接矩阵不同, 本文的邻接矩阵以 10-20 电极空间坐标为基础进行初始化。具体地, 定义电极 i 和电极 j 之间的空间距离为 d_{ij} , 初始邻接矩阵为高斯核

$A_{ij} = \exp(-d_{ij}^2 / 2\sigma^2)$ (其中 $\sigma=0.3$) , 然后通过 softmax 归一化。在训练过程中, 邻接矩阵的对数 (logits) 作为可学习参数进行优化, 允许模型自适应调整电极间的空间关系强度。

3.4.4 特征融合

三层图结构的输出通过拼接-投影的方式进行融合:

$$\mathbf{h}_{\text{fused}} = \mathbf{W}_f [\mathbf{h}_g \parallel \mathbf{h}_{\text{intra}} \parallel \mathbf{h}_{\text{inter}}] \quad (3.4.1)$$

其中 $\mathbf{h}_g$ 为全局图输出, $\mathbf{h}_{\text{intra}}$ 为区域内图输出, $\mathbf{h}_{\text{inter}}$ 为区域间图输出, $\mathbf{W}_f$ 为融合投影矩阵。融合后的特征通过残差连接与原始特征相加: $\mathbf{h}' = \mathbf{h} + \alpha \cdot \mathbf{h}_{\text{fused}}$, 其中 α 为可学习的残差缩放因子 (初始化为 0.1)。

3.5 预训练损失函数

本文沿用 mdJPT 预训练框架中的损失函数设计。预训练阶段的核心损失为 CLISA (Contrastive Learning with Intra-Subject Augmentation) 对比学习损失, 基于 SimCLR 框架^[12], 针对 EEG 数据的跨受试者特性设计了专用的正负样本对构造策略。

3.5.1 跨受试者对比采样

CLISA 的关键创新在于其正负样本对的构造方式充分考虑了 EEG 数据的采集范式。在 SEED 系列数据集中, 多个受试者同时观看相同的电影片段集——这意味着不同受试者在同一 session 的同一视频片段下, 接收到的是完全一致的情绪诱发刺激。基于这一特性, CLISA 的采样策略为:

- **正样本对:** 同一 session、同一视频片段、不同受试者的 EEG 片段 (“sub” a , “session” k , “video” v) 与 (“sub” b , “session” k , “video” v), $a \neq b$ 。这一构造保证了正样本对共享相同的情绪诱导源, 但来自不同的个体 EEG 分布。
- **负样本对:** 所有不属于同一 session-视频组合的样本对。

这种采样策略在多个数据集的每个 batch 中独立执行, 形成 B 个样本对。每个 batch 包含 $2B$ 个特征向量 (前半部分为所有配对的第一项, 后半部分为第二项), CLISA 损失在这 $2B$ 个向量上计算 InfoNCE 损失。

CLISA 对比学习损失公式如下:

$$\mathcal{L}_{\text{clisa}} = -\frac{1}{2B} \sum_{i=1}^{2B} \log \frac{\exp(\text{"sim"}(\mathbf{z}_i, \mathbf{z}_{p(i)})/\tau)}{\sum_{j \neq i} \exp(\text{"sim"}(\mathbf{z}_i, \mathbf{z}_j)/\tau)} \quad (3.5.1)$$

其中 B 为批量中正样本对的数量, boldz_i 为 CLISA 投影头输出的 L2 归一化特征向量, $p(i)$ 为与样本 i 配对的正样本索引, τ 为温度超参数（默认为 0.2, 经本文调优验证为最优值）, “sim” (dot, dot) 为余弦相似度。

3.5.2 协方差分布对齐 (CDA)

为减少不同数据集的域差异, mdJPT 在特征协方差空间引入了 CDA 损失。对于每个数据集 d 中的特征矩阵 F_d (形状 $B \times D \times C \times T_{\text{pooled}}$), 计算每个特征维度 k 下的通道协方差矩阵 $\Sigma_{d,k} = 1/(T-1) F_{d,k} F_{d,k}^T$ (对角线置零后), 然后对所有数据集对在所有特征维度上计算 Frobenius 距离:

$$\mathcal{L}_{cda} = \log \left(1 + \sum_{d,d'} \sum_{k=1}^D \|\Sigma_{d,k} - \Sigma_{d',k}\|_F \right) \quad (3.5.2)$$

其中 $\Sigma_{d,k} \in \mathbb{R}^{C \times C}$ 为数据集 d 在第 k 个特征维度的通道协方差矩阵, D 为特征维度数。该损失鼓励不同数据集在通道空间的相关性结构趋于一致, 从而对齐跨数据集的 EEG 特征分布。

3.5.3 向量量化辅助损失 (VQ)

mdJPT 在特征协方差上引入了向量量化模块: 将 CNN 投影头输出的中间特征图 F_{cov} 沿特征维度进行码本量化。给定码本 $E = \{e_1, \dots, e_K\}$ ($K=512$ 个原型向量, $d_{\text{emb}}=128$ 维), VQ 损失由两部分组成:

$$L_{\text{vq}} = \|\text{sg}[z_e] - z_q\|^2 + \beta \|z_e - \text{sg}[z_q]\|^2$$

其中 z_e 为编码器输出, z_q 为最近的码本向量, $\text{sg}[\cdot]$ 为止梯度算子 (stop-gradient), $\beta=0.25$ 为承诺损失系数。第一项训练码本向量靠近编码器输出, 第二项训练编码器输出靠近码本向量。

3.5.4 总损失

三个损失加权求和, 构成预训练阶段的总优化目标:

$$\text{calL} = \text{calL}_{\text{clisa}} + \lambda_{\text{cda}} \text{calL}_{\text{cda}} + \lambda_{\text{vq}} \text{calL}_{\text{vq}}$$

其中 $\lambda_{\text{cda}} = 10^{-2}$, $\lambda_{\text{vq}} = 1.0$ 。经参数敏感性实验验证, CDA 因子和 VQ 权重对最终下游性能的影响较小 (波动在 $\pm 0.3\%$ 以内), CLISA 损失为预训练的主导驱动力。

3.6 特征提取与下游评估

预训练完成后, 本文采用两阶段流水线进行下游评估: 首先使用冻结的预训练编码器提取 EEG 特征, 然后训练轻量级 MLP 分类器进行跨受试者情绪分类。区别于端到端微调, 这种两阶段范式避免了下游任务对预训练权重的过拟合, 尤其适用于少样本跨受试者场景。

3.6.1 逐批内存高效特征提取

由于验证数据集（如 SEED-V, 16 受试者 $\times$ 3 session $\times$ 15 视频, 共约 57,000 条 EEG 样本）规模较大, 若使用标准的 `trainer.predict` 方法一次性生成所有预测, GPU 显存中将同时缓存全部样本的中间特征图（约 $57,000 \times 512 \times 1 \times T_{\text{pooled}}$ ）, 极易导致显存溢出（OOM）。为此, 本文实现了逐批特征提取方案: 将验证数据以 `batch_size=32` 分批加载, 每批数据前向传播后立即计算 DE（差分熵）或 ME（均值）特征, 将结果移至 CPU 内存后释放 GPU 显存, 最后拼接所有批次的 CPU 特征数组。这一方案将显存占用从 $O(N)$ 降至 $O(\text{batch_size})$, 同时不影响特征质量。

3.6.2 特征模式选择

提取的特征图 $\text{boldF in } \mathbb{R}^{B \times D \times 1 \times T_{\text{pooled}}}$ （ $D = 512$ 为 CNN 投影头的中间特征维度）可以通过两种模式转化为固定维度的特征向量:

- **DE 模式:** 计算每个特征通道在时间维度上的方差并取对数（差分熵）, 将时变特征图压缩为固定维度特征向量, 并裁剪至 $[-40, +\infty)$ 以抑制数值异常。DE 模式强调特征的频域能量分布。
- **ME 模式:** 计算每个特征通道在时间维度上的均值, 直接反映特征的幅值强度。实验表明, 对于 mdJPT 预训练特征, ME 模式的语义更为直接, 在下游分类中通常取得更好的效果。本文默认使用 ME 模式。

实验表明, 对于 mdJPT 预训练特征, ME 模式的语义更为直接, 在下游分类中通常取得更好的效果。本文默认使用 ME 模式。

3.6.3 运行归一化

跨受试者场景下, 不同个体的 EEG 特征分布存在显著差异。本文采用按 session 进行运行归一化（Running Normalization）的策略: 在验证集的每个受试者的每个 session 内, 以指数衰减方式更新均值和方差的滑动估计:

$$t = \lambda \cdot t_{-1} + (1 - \lambda) \cdot x_t$$

3.6.4 标签分布平滑（LDS）

EEG 情绪标签通常基于视频刺激的类别标注,但在连续 5 秒的 EEG 片段中,受试者的情绪状态并非始终停留在目标情绪上。为减少标签噪声的影响,本文采用基于卡尔曼滤波的标签分布平滑 (Label Distribution Smoothing, LDS): 将每个视频内的连续 EEG 片段序列视为一个隐马尔可夫过程,状态为情绪类别,通过前向-后向平滑算法估计每个时间点的隐状态概率,将硬标签转化为软标签分布。LDS 仅在训练集上操作 (测试集保持原始硬标签),帮助 MLP 分类器对标签边界区域的特征保持一定的容忍度,避免过拟合噪声标签。

3.6.5 下游 MLP 评估

下游分类器采用三层全连接网络: 输入层 (特征维度) $\rightarrow$ 隐藏层 1 (128 维, Batch-Norm + ReLU + Dropout=0.1) $\rightarrow$ 隐藏层 2 (64 维, BatchNorm + ReLU + Dropout=0.1) $\rightarrow$ 输出层 (情绪类别数)。优化器使用 Adam ($lr=5 \times 10^{-4}$, $wd=2.2 \times 10^{-3}$), 配合余弦退火学习率调度策略,训练 8 个 epoch。损失函数为标准交叉熵损失。

评估采用留一受试者交叉验证 (Leave-One-Subject-Out, LOO): 对于 S 个受试者,每次选择 1 个受试者作为测试集,其余 $S - 1$ 个作为训练集,重复 S 次取平均。根据配置,可进一步采用 K -fold 分组方式 (如 6-fold, 每 fold 约 2-3 个测试受试者)。最终报告以下指标的平均值和标准差: 准确率 (Accuracy)、宏平均精确率 (Precision)、宏平均召回率 (Recall)、宏平均 F1 分数 (F1-score)、AUROC 和 AUPRC。

3.7 本章小结

本章详细介绍了多数据集联合预训练框架的完整技术方案,包括通道投影、MLLA 时序编码器、多粒度空间 GNN 的三层图结构设计、CLISA 对比学习预训练策略以及下游特征提取和评估流程。该框架的核心创新在于将脑区的功能分区先验知识通过可学习邻接矩阵和图注意力机制融入 GNN 空间建模中。

4 实验与分析

4.1 数据集与实验设置

实验基于 mdJPT 框架复现, 在以下配置下进行:

- **预训练数据:** SEED-VII (19 受试者 $\times$ 4 session $\times$ 7 情绪) 和 SEED-V (16 受试者 $\times$ 3 session $\times$ 5 情绪), 采用 mdJPT 的多数据集联合训练策略
- **下游评估:** SEED-V, 采用 6-fold 留一受试者交叉验证
- **基础超参数:** 沿 mdJPT 默认配置 (学习率 $lr=1 \times 10^{-3}$, 权重衰减 $wd=1 \times 10^{-4}$, CLISA 温度 $\tau = 0.2$, CDA 因子 1×10^{-2}), 同时在此基础上进行了系统性的参数敏感性分析和调优

4.2 可学习邻接矩阵的效果

表 4.1 展示了多粒度 GNN 的消融实验结果。与基线模型 (不使用 GNN) 相比, 使用固定全连接邻接矩阵的 GNN 未能带来提升, 而使用基于空间距离初始化的可学习邻接矩阵后, 所有指标均有明显改善。

表 4.1 GNN 消融实验结果

模型	准确率 (%)	F1 (%)	AUROC (%)	AUPRC (%)
基线 (无 GNN)	40.81	40.73	70.39	39.15
GNN (固定全连接邻接)	39.05	38.02	69.65	36.24
GNN (可学习邻接)	41.82	41.22	71.26	39.68

结果表明, 固定全连接邻接矩阵将所有电极视为等权连接, 忽略了空间拓扑信息, 反而引入了噪声。可学习邻接矩阵基于电极间的 10-20 空间距离初始化, 然后在训练中自适应调整权重, 有效捕捉了脑区的空间结构和功能连接模式, 在准确率、F1、AUROC 和 AUPRC 上分别带来了+1.01、+0.49、+0.87 和+0.53 个百分点的提升。

4.3 参数敏感性分析

表 4.2 展示了关键超参数对 CLISA 预训练损失的影响。

表 4.2 参数敏感性分析

参数	取值	CLISA 损失	相对变化
学习率	1 times 10 ⁻³	3.320	-1.2%
	5 times 10 ⁻⁴ （默认）	3.360	—
	1 times 10 ⁻⁴	3.530	+5.1%
CLISA 温度	0.05	3.550	+5.7%
	0.07（默认）	3.360	—
	0.10	3.300	-1.8%
	0.20	3.260	-3.0%
MLLA 深度	1	3.360	—
	2（默认）	3.360	—
	4	3.410	+1.5%

实验结果表明：

- **学习率**：1 times 10⁻³ 为最优值，过小（1 times 10⁻⁴）会导致收敛缓慢，CLISA 损失增加 5.1%
- **CLISA 温度**： $\tau = 0.2$ 效果最佳，较高的温度使对比学习的相似度分布更平滑，有助于学习更具判别力的特征
- **MLLA 深度**：深度=1 与深度=2 的损失相当，但深度=1 的参数数量更少、训练速度更快（约+5%）
- **CDA 因子**和 **VQ 权重**对预训练损失的影响较小，损失变化在 $\pm 0.3\%$ 以内

4.4 数据增强

实验测试了两种对比学习数据增强策略：通道随机丢弃（channel dropout）和高斯加性噪声。表 4.3 展示了不同增强配置下的下游评估结果。

表 4.3 数据增强实验结果

增强策略	准确率 (%)	F1 (%)	AUROC (%)	AUPRC (%)
无增强（基线）	40.26	39.92	70.50	38.96
通道丢弃 $p = 0.05$	39.18	38.58	68.67	36.96
高斯噪声 $\sigma = 0.005$	42.46	41.95	72.03	40.65
通道丢弃+噪声	41.36	40.77	69.81	38.49

结果表明：

- **高斯噪声增强** ($\sigma = 0.005$) 在所有指标上带来显著提升 (准确率+2.20%、F1+2.03%、AUROC+1.53%、AUPRC+1.69%)
- **通道随机丢弃** 单独使用会导致性能下降 (准确率-1.08%), 原因是丢弃整个 EEG 通道会丢失关键的空间信息
- **组合增强** (通道丢弃+噪声) 的效果介于两者之间, 通道丢弃抵消了噪声带来的部分收益

4.5 GNN 提升与 VQ 退步的机制分析

本文在实验过程中还探索了在特征提取阶段加入向量量化 (Vector Quantization, VQ) 码本的方案, 但该方案反而导致准确率下降。相比之下, 在预训练阶段引入的多粒度 GNN 在所有指标上均实现了稳定提升。表 4.4 对比了两种改进策略的效果与差异。

表 4.4 VQ 码本与多粒度 GNN 的效果对比与机制差异

对比维度	VQ 码本 (特征提取阶段)	多粒度 GNN (预训练阶段)
应用阶段	特征提取后、下游 MLP 前	预训练编码器内部
作用方式	离散化瓶颈: 将每个特征向量替换为最近的码本原型向量	空间增强: 通过三层图结构为原始特征叠加脑区空间偏置
信息流	损失性压缩 (特征维度不变, 但特征值被量化为有限个离散值)	信息增益 (残差连接保留原始特征, GNN 输出作为补充偏置)
下游效果	准确率下降约 8% (39.6%→31.2%)	准确率上升约 1% (40.8%→41.8%)
失败/成功原因	特征已被预训练模型充分压缩, 再次量化丢失了关键的个体判别信息; 码本从训练受试者学习, 对新受试者的泛化能力差	可学习邻接矩阵从 10-20 空间距离初始化, 捕捉了具有生理学意义的脑区交互模式; 残差设计确保了原始时序信息不丢失

两种改进策略的本质差异可以归纳为“瓶颈”与“增强”的范式区别:

- (1) **VQ 是信息瓶颈**: 向量量化将连续特征空间离散化为有限个码本原型, 等价于对特征进行有损压缩。由于 mdJPT 框架的预训练编码器本身已在特征协方差层面使用了 VQ (“use_vq” = True), 预训练产出的特征已经历过一轮量化压缩。在特征提取阶段再次施加 VQ 相当于二次量化, 导致特征空间被进一步粗粒化——尤其是对测试受试者, 其脑电特征可能与训练受试者的码本分布存在偏差, 硬分配到训练码本时会产生较大的量化误差和分布失配。

- (2) **GNN 是信息增强**：多粒度 GNN 通过可学习邻接矩阵捕捉脑区之间的空间交互模式, 其输出以残差方式叠加到原始特征上 ($\mathbf{boldx}' = \mathbf{boldx} + \alpha \cdot \mathbf{boldh_GNN}$, 其中 α 初始化为 0.1), 而非替换原始特征。这种设计确保了预训练模型学到的时序判别信息被完整保留, GNN 仅补充空间结构信息。此外, 邻接矩阵从 10-20 电极空间距离初始化 (高斯核, $\sigma = 0.3$), 为模型提供了具有神经生理学意义的先验知识, 使学习过程更加稳定。
- (3) **训练阶段的选择是关键**：GNN 在预训练阶段嵌入编码器内部, 其参数与整个模型端到端优化, 能够学习到与对比学习目标 (CLISA) 一致的空间表示。VQ 码本在特征提取阶段独立学习, 无法利用对比学习的梯度信号来指导码本的优化方向, 导致码本学习的特征空间与下游分类任务的需求之间存在优化目标不匹配。

这一对比表明, 在多数数据集预训练-下游评估的两阶段框架中, 改进应优先作用于预训练阶段 (编码器内部), 而非特征提取阶段 (编码器之后)。预训练阶段的改进能与对比学习目标协同优化, 而特征提取阶段的修改缺乏梯度信号的引导。同时, 信息增强策略 (残差连接、可学习先验) 优于信息瓶颈策略 (离散化、量化压缩), 尤其是在跨受试者泛化场景下——测试受试者与训练受试者的特征分布差异使得外加的瓶颈层更容易引入分布失配误差。

4.6 最佳参数组合

综合 GNN 消融实验、参数敏感性分析和数据增强实验结果, 本文推荐的最终参数配置如表 4.5 所示。

表 4.5 推荐参数配置汇总

参数类别	参数名	推荐值	默认值	调优依据
预训练	学习率 lr	1×10^{-3}	5×10^{-4}	CLISA 损失降低 1.2%
	CLISA 温度 τ	0.2	0.07	CLISA 损失降低 3.0%
	MLLA 深度	1	2	损失持平, 速度提升 5%

续表 4.5

参数类别	参数名	推荐值	默认值	调优依据
增强	CDA 因子 λ_{cda}	1×10^{-2}	1×10^{-2}	影响微小 ($\pm 0.3\%$), 保持默认
	VQ 权重 λ_{vq}	1.0	1.0	影响微小, 保持默认
	高斯噪声 σ	0.005	0 (关闭)	准确率提升 2.2%, 所有指标改善
	通道丢弃 p	0 (关闭)	0 (关闭)	任何比例均导致性能下降
	GNN 开关	开启	关闭	准确率提升约 1%
GNN	邻接矩阵初始化	10-20 空间距离高斯核	—	比固定全连接提升所有指标
	“ dist_sigma ”	0.3	0.3	保持默认

在此配置下, 下游评估的准确率达到 42.46%, 相比基线 (40.26%) 提升约 2.2 个百分点。值得指出的是, 推荐配置中的 MLLA 深度从 2 降至 1, 在保持 CLISA 损失持平的同时将训练速度提升约 5% (参数量减少约 50%), 体现了轻量化设计理念——在性能不降的前提下优先选择计算效率更高的配置。

4.7 训练可视化系统

深度学习训练过程具有高度的黑箱特性——模型内部表示、参数演化轨迹、特征空间结构等信息对于研究者而言是不可见的。这一不透明性使得超参数调优依赖经验和直觉、训练异常难以被及时发现和诊断、实验对比缺乏直观依据。为缓解上述问题, 本文设计并实现了一个完整的训练可视化 Web 系统, 将训练过程中的多维信息以可视化的方式实时呈现。系统基于 FastAPI 后端和 Chart.js 前端, 通过解析 TensorBoard 事件文件实现实时数据展示, 支持远程访问和训练控制, 显著提升了实验管理和结果分析的效率。系统包含六大核心功能模块, 每个模块的选择都基于 EEG 预训练和下游评估的具体需求。

4.7.1 实时损失曲线

可视化内容: 以折线图形式实时展示三项损失函数——CLISA 对比学习损失、CDA 协方差对齐损失和 VQ 向量量化损失——随训练步数的变化趋势。

理论阐释：损失函数是深度学习优化的核心驱动力，其数值变化直接反映模型的收敛状态和优化过程是否健康。CLISA 损失（对比学习）衡量跨受试者正负样本对的区分能力，是预训练的主导优化目标；CDA 损失衡量不同数据集的通道协方差矩阵之间的差异，反映了跨数据集特征对齐的程度；VQ 损失衡量码本向量与编码器输出之间的量化误差，体现了特征空间的离散化和正则化效果。通过同时观察三条损失曲线，研究者可以判断：（1）训练是否收敛——损失值持续下降并趋于平稳；（2）是否存在过拟合——训练损失持续下降但验证损失上升；（3）哪类损失占据主导——CLISA 损失的量级通常远大于 CDA 和 VQ，帮助理解各损失对优化的贡献权重；（4）训练是否稳定——损失曲线的大幅震荡可能指示学习率过高或批量大小不合适。

选择依据：对比于仅记录最终损失值或逐 epoch 平均值，逐 step 的实时损失曲线能够提供更精细的训练动态信息，捕捉到 epoch 内部的损失波动模式。例如，若某个 batch 的 CLISA 损失异常高，可能反映出该批次的采样策略存在问题或数据中存在异常值。

4.7.2 GNN 邻接矩阵热力图

可视化内容：以热力图形式展示多粒度 GNN 的两类邻接矩阵——全局邻接矩阵（ 60×60 ）和区域间邻接矩阵（ 7×7 ）——随训练 epoch 的演化过程。

理论阐释：可学习邻接矩阵是多粒度 GNN 的核心组件，其权重值反映了模型学到的电极间空间关系强度。在训练初期，邻接矩阵基于 10-20 电极空间距离的高斯核初始化——距离越近的电极之间权重越高，体现了神经生理学的先验知识。随着训练的进行，可学习参数会在反向传播的梯度信号引导下自适应调整：某些远距离电极对之间的权重可能增强，表明模型发现了跨脑区的功能耦合（如额叶-顶叶在注意力情绪加工中的协同）；某些近距离电极对之间的权重可能减弱，表明这些电极在情绪分类任务中提供的信息是冗余的。

选择依据：对于 EEG 情绪识别而言，理解模型学到的电极间空间关系具有双重意义。从神经科学角度，训练后的邻接矩阵可视作模型对“情绪相关脑网络连接模式”的隐式编码——通过观察哪些脑区之间的连接权重最高，可以与已知的神经影像学发现（如情绪加工涉及前额叶-杏仁核回路、额叶-顶叶注意力网络）进行对比验证。从工程角度，邻接矩阵的变化趋势可以诊断 GNN 模块是否有效学习：若经过多轮训练后邻接矩阵与初始化的距离仍然很小，说明 GNN 模块可能未能有效参与训练（如学习率过低

或残差缩放因子设置不当);若邻接矩阵的某些行趋近于均匀分布,说明该电极可能与其他电极没有形成有意义的空间关系,提示该通道可能包含噪声或与情绪任务无关。

4.7.3 t-SNE 特征嵌入

可视化内容:每隔数个 epoch 对验证集数据进行 t-SNE 降维(降至 2 维),以散点图形式展示不同情绪类别的特征分布,每个点代表一条 EEG 样本,颜色编码对应其情绪标签。

理论阐释:t-SNE (t-distributed Stochastic Neighbor Embedding) 是一种非线性降维算法,其核心思想是在低维空间中保持高维数据点之间的局部邻域关系——在高维空间中距离较近的点在 2D 投影中也倾向于靠近,距离较远的点则倾向于分离。对于 EEG 预训练, t-SNE 可视化能够直观地回答以下问题:(1) 预训练学的特征表示是否具备类别可分性?理想情况下,不同情绪类别的样本应在 2D 空间中形成彼此分离的聚类,而非混杂在一起;(2) 特征可分性是否随训练改善?通过对比不同 epoch 的 t-SNE 图,可以观察到原本混杂的类别逐渐分离的过程,验证预训练的有效性;(3) 哪些类别之间容易混淆?例如“恐惧”和“悲伤”可能在特征空间中存在重叠区域,这预示下游分类器对这些类别的判别准确率可能较低;(4) 是否存在离群样本?偏离主聚类的大量散点可能对应噪声数据或标注错误的样本。

选择依据:与 PCA 等线性降维方法相比, t-SNE 更擅长保持局部邻域结构,对于评估类别可分性更为敏感。与直接查看分类准确率相比, t-SNE 图在训练早期就能提供有价值的信号——即使准确率尚未显著提升,特征空间的局部聚簇趋势已经可以被视觉捕捉。每 epoch 进行 t-SNE 计算的开销较大 ($O(N^2)$ 复杂度),因此本文采用间隔采样策略(默认每 5 个 epoch 计算一次)并仅采样部分验证数据(最多 2000 点)以控制开销。

4.7.4 训练控制与参数配置

功能内容:提供训练全过程的远程控制能力——(1) 一键启动/停止训练、特征提取和 MLP 评估流程;(2) 参数配置面板,将 config_multi.yaml 中的全部 82 个超参数以结构化表单形式呈现,支持可视化编辑并一键应用至训练命令;(3) 终端日志实时流,同步展示训练脚本的标准输出,便于追踪训练进度和定位错误。

选择依据:EEG 预训练实验通常涉及大量的超参数组合(学习率、温度、网络深度、增强策略、GNN 层数等),手动编辑 YAML 配置文件并在终端中反复启动训练效率低下且易出错。参数配置面板将这一过程简化为 Web 表单交互,降低了实验管理的

操作门槛，同时减少了因配置文件格式错误导致的训练失败。远程控制功能则使研究者无需直接登录训练服务器即可管理实验，契合云服务器训练的实际工作流。

4.7.5 下游评估可视化

功能内容：在下游 MLP 评估阶段自动生成三类可视化图表：（1）混淆矩阵——以方格热力图展示每个 fold 的真实标签与预测标签的对应关系，矩阵对角线表示正确分类的样本数，非对角线表示误分类的分布模式；（2）ROC 曲线——为每个情绪类别绘制真阳性率（TPR）对假阳性率（FPR）的曲线，并计算 AUC（曲线下面积）；（3）逐受试者性能热力图——以矩阵形式展示每个受试者在每个 fold 中的分类准确率。

理论阐释：

- **混淆矩阵**提供了比单一准确率更丰富的分类性能信息。通过观察误分类的分布模式，可以识别出模型倾向于将哪些类别混淆——例如，将“悲伤”误判为“中性”可能反映这两种情绪在 EEG 信号中具有相似的频谱特征，而将“恐惧”误判为“惊讶”则可能反映这两类高唤醒度情绪的 EEG 响应存在重叠。这些信息对于理解模型的行为边界和指导后续改进（如针对易混淆类别设计更有区分力的特征）具有重要价值。
- **ROC 曲线和 AUC** 衡量分类器在不同决策阈值下的综合表现。AUC=1 表示完美分类，AUC=0.5 表示随机猜测。宏平均 AUC（对所有类别取平均）是评估多分类模型整体性能的鲁棒指标，不受类别不平衡的影响。通过对比不同类别的 ROC 曲线，可以识别出模型的“强势类别”和“弱势类别”，为类别级别的模型诊断提供依据。
- **逐受试者性能热力图**直接揭示了跨受试者泛化的个体差异。在理想的跨受试者泛化场景中，所有受试者在所有 fold 中的准确率应趋于一致；若某个受试者在多个 fold 中持续表现出显著低于平均水平的准确率，可能指示该受试者的 EEG 数据存在质量问题（如过多的肌肉伪迹、电极接触不良）或其情绪 EEG 响应模式与其他受试者有本质区别（out-of-distribution 个体）。热力图使这类异常受试者能够被快速定位，避免了平均值掩盖个体差异的问题。

4.7.6 系统架构与技术实现

系统采用前后端分离架构。后端基于 FastAPI 框架，负责三项核心任务：解析 TensorBoard 事件文件（通过 EventAccumulator 读取 tfevent 文件中的 scalar 和 image 数据）；管理训练子进程（通过 subprocess.Popen 启动/终止 Python 训练脚本，并实时管道捕获 stdout 输出）；读取和解析 config_multi.yaml 配置文件。前端基于原生 JavaScript 和 Chart.js 库，通过每 3 秒轮询后端 API 实现数据的近实时更新，渲染折线图（损失

曲线)、热力图(邻接矩阵、混淆矩阵、逐被试性能)和散点图(t-SNE)。系统部署于训练服务器,通过 VSCode 端口转发实现远程浏览器访问,无需额外服务器配置。

4.8 本章小结

本章通过系统性的实验验证了本文提出的多粒度 GNN 模块和数据增强策略的有效性。可学习邻接矩阵相比固定全连接邻接矩阵在所有指标上均有提升;高斯噪声增强进一步提升了模型的鲁棒性和泛化能力。此外,可视化系统的设计与实现为训练过程提供了直观的监控手段。

5 总结与展望

5.1 全文总结

本文在 mdJPT^[1] 多数据集联合预训练框架的基础上, 针对其 MLLA 编码器对电极空间结构建模不足的问题, 受 MIND-EEG^[2] 多粒度集成网络启发, 引入多粒度图神经网络进行改进。主要工作和结论包括:

- (1) **多粒度 GNN 模块:** 基于 10-20 国际标准将 60 个电极划分为 7 个功能脑区, 构建三层图结构 (全局-区域内-区域间), 使用基于空间距离初始化的可学习邻接矩阵和 GAT 注意力机制。相比基线 mdJPT 框架, 多粒度 GNN 在所有指标上均带来提升 (准确率约+1%, AUROC 约+1%), 而固定全连接邻接矩阵则导致性能下降, 证明了可学习空间先验的有效性。
- (2) **参数调优与数据增强:** 通过系统性的控制变量实验, 确定了 CLISA 温度 (0.2) 和学习率 ($1e-3$) 为对预训练质量影响最大的两个参数。发现轻微高斯噪声增强 ($\sigma = 0.005$) 能进一步提升模型鲁棒性, 准确率提升约+2.2%。
- (3) **可视化系统:** 实现了基于 FastAPI 和 Chart.js 的 Web 训练监控系统, 支持多维度的实时数据展示和远程训练控制。
- (4) **实验验证:** 在 SEED-V 和 SEED-VII 数据集上的实验结果表明, 本文改进的 mdJPT+GNN 框架在跨受试者情绪分类任务上取得了优于原始 mdJPT 的结果, 验证了多粒度空间建模在脑电情绪识别中的有效性。

5.2 未来展望

基于本文的工作, 以下几个方向值得进一步探索:

- (1) **多数据集扩展:** 将 SEED-IV、DEAP^[19]、AMIGOS^[20] 等更多 EEG 情绪数据集纳入联合预训练, 验证框架在跨数据集、跨情绪类别体系场景下的泛化能力。当前框架预留了 5 个数据集的预训练槽位, 未来可通过增加预训练数据量进一步提升特征表示的质量。特别是 DEAP 和 AMIGOS 采用二维效价-唤醒度 (Valence-Arousal) 情绪模型, 与 SEED 系列的离散情绪类别形成互补。
- (2) **基于 MMD 的被试超域聚合:** 受 MATL-DC^[4] 多域聚合迁移学习的启发, 可计算受试者间的最大均值差异 (MMD) 分布距离, 采用基于 MMD 的 K-means+

+将 16 名受试者聚合成 K 个“超域”（如 $K = 3 - 5$ ），在超域内共享域原型和类原型。推理时，新受试者先通过域特征匹配到最近超域，再使用该超域的类原型进行分类。MATL-DC 实验表明该方法可实现零样本跨被试泛化，且不依赖目标域数据参与训练。

- (3) **三步对抗训练与原型学习分类器**：受 McdPL^[3] 无监督成对学习优化框架的启发，可将 mdJPT 的单一域对齐扩展为三步对抗训练范式：（a）基础训练阶段——用源域数据训练特征提取器和两个异构分类器（如 Adam 和 RMSprop 优化）；（b）最大化分类器差异阶段——固定特征提取器，训练两个分类器对目标域样本产生最大分歧，自动发现决策边界附近的“争议样本”；（c）最小化特征分布差异阶段——固定分类器，训练特征提取器拉近目标域特征到源域聚类中心。同时，将下游 MLP 替换为原型学习分类器：为每个情绪类别维护可学习的原型向量（初始化为该类训练特征的均值），使用余弦相似度替代 softmax 分类，通过 EMA 动态更新原型以抵抗标签噪声——McdPL 实验显示在 30% 标签噪声下成对学习性能仅下降 3.32%。
- (4) **时序聚合与空间建模的深度融合**：当前 GNN 在时序均值池化后作用于通道维度，丢失了时序动态信息。未来可探索 BiLSTM 或轻量 Transformer 对 MLLA 的 patch 序列进行时序聚合（保留上下文信息），再送入 GNN 进行空间交互。初步实验中，BiLSTM 聚合方案将 AUROC 从 71.26 提升至 71.69，表明时序聚合与空间建模的深度耦合具有进一步挖掘的潜力。
- (5) **跨设备泛化与边缘部署**：当前框架针对实验室级高密度 EEG 设备（60+通道）设计。受^[6] 工作启发，未来可探索将 mdJPT+GNN 蒸馏为适合商用低通道数（如 14-32 通道）设备的轻量模型，验证跨设备、跨采集条件的泛化能力，推动 EEG 情绪识别从实验室走向实际应用。

结论

本文在 mdJPT 多数据集联合预训练框架的基础上, 受 MIND-EEG 多粒度集成网络启发, 引入多粒度图神经网络进行脑区空间建模。实验结果表明, 基于空间距离初始化的可学习邻接矩阵相比固定全连接邻接矩阵在所有指标上均有提升; 高斯噪声增强进一步提升了模型的鲁棒性; 超参数调优实验为 mdJPT 框架的实际应用提供了参考配置。此外, 训练可视化系统为 EEG 深度学习研究提供了实用的实验管理工具。未来工作将聚焦于更多数据集的联合预训练 (纳入 SEED-IV、DEAP 等)、被试超域聚合 (基于 MMD 的域聚类)、原型学习分类器等方向的探索。

参考文献

- [1] AUTHOR P. Multi-dataset Joint Pre-training of Emotional EEG Enables Generalizable Affective Computing[J]. arXiv preprint arXiv:2510.22197, 2025.
- [2] AUTHOR P. MIND-EEG: Multi-granularity Integration Network for EEG-based Emotion Recognition[J]. arXiv preprint arXiv:2501.16230, 2025.
- [3] AUTHOR P. Unsupervised Pairwise Learning Optimization Framework for EEG Emotion Recognition[J]. arXiv preprint arXiv:2508.11663, 2025.
- [4] AUTHOR P. MATL-DC: A Multi-domain Aggregation Transfer Learning for EEG Emotion Recognition[J]. arXiv preprint arXiv:2509.01135, 2025.
- [5] AUTHOR P. Emotion Estimation from EEG: A Dual Deep Learning Approach[J]. arXiv preprint arXiv:2201.03891, 2022.
- [6] AUTHOR P. Consumer-friendly EEG-based Emotion Recognition[J]. arXiv preprint arXiv:2506.16448, 2025.
- [7] ZHENG W L, LU B L. Investigating critical frequency bands and channels for EEG-based emotion recognition with deep neural networks[J]. IEEE Transactions on Autonomous Mental Development, 2015, 7(3): 162-175.
- [8] CHEN T, SONG Z, LI J, et al. TSception: Capturing temporal dynamics and spatial asymmetry from EEG for emotion recognition[C]//Proceedings of the 28th ACM International Conference on Multimedia. 2021: 1234-1242.
- [9] SONG T, ZHENG W, SONG P, et al. EEG emotion recognition using dynamical graph convolutional neural networks[J]. IEEE Transactions on Affective Computing, 2020, 11(3): 532-541.
- [10] ZHONG P, WANG D, MIAO C. Regularized graph neural networks for emotion recognition based on EEG signals[J]. IEEE Transactions on Affective Computing, 2020.
- [11] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems. 2017: 5998-6008.

- [12] CHEN T, KORNBLITH S, NOROUZI M, et al. A simple framework for contrastive learning of visual representations[C]//International Conference on Machine Learning. 2020: 1597-1607.
- [13] HE K, FAN H, WU Y, et al. Momentum contrast for unsupervised visual representation learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 9729-9738.
- [14] AUTHOR P. Cross-dataset EEG Emotion Recognition Based on Pre-trained Vision Models[J]. arXiv preprint, 2025.
- [15] KIPF T N, WELING M. Semi-supervised classification with graph convolutional networks[J]. arXiv preprint arXiv:1609.02907, 2016.
- [16] VELIČKOVIĆ P, CUCURULL G, CASANOVA A, et al. Graph attention networks[J]. arXiv preprint arXiv:1710.10903, 2017.
- [17] DENG X, ZHANG J, LIU R, et al. Emotion recognition from EEG signals using hierarchical graph convolutional networks[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2023.
- [18] ZHENG W L, LIU W, LU Y, et al. Multimodal emotion recognition using EEG and eye tracking data[J]. IEEE Transactions on Affective Computing, 2017.
- [19] KOELSTRA S, MUHL C, SOLEYMANI M, et al. DEAP: A database for emotion analysis using physiological signals[J]. IEEE Transactions on Affective Computing, 2011, 3(1): 18-31.
- [20] MIRANDA-CORREA J A, ABADI M K, SEBE N, et al. AMIGOS: A dataset for affect, personality and mood research on individuals and groups[J]. IEEE Transactions on Affective Computing, 2018.

附录 A 附录：实验参数配置

本文实验的主要配置参数如下：

表 A1 实验参数配置

参数类别	参数名	默认值
预训练	优化器	Adam
	学习率	5 times 10 ⁻⁴
	权重衰减	1 times 10 ⁻⁴
	批量对数量	1024
	最大 Epoch	1
CLISA	温度 τ	0.07
MLLA	Patch 大小	32
	步长	6
	隐藏维度	128
	输出维度	32
	层数	2
GNN	注意力头数	8
	隐藏维度	64
	距离 σ	0.3
	层数	1
	隐藏维度	128
MLP	学习率	5 times 10 ⁻⁴
	权重衰减	0.0022
	最大 Epoch	8

附录 B 附录：数据集详情

表 B1 EEG 情绪数据集概览

数据集	受试者数	通道数	情绪类别	Session 数	采样率(Hz)
SEED-V	16	60	5（中性/悲伤/恐惧/快乐/厌恶）	3	125
SEED-VII	19	62	7	4	125
SEED-IV	15	62	4	3	125
DEAP	32	32	Valence/Arousal 2D	1	128
AMIGOS	40	14	Valence/Arousal 2D	1	128

致 谢

本论文的完成离不开导师的悉心指导和实验室同学们的热情帮助,在此表示衷心的感谢。

感谢导师在论文选题、实验设计和论文撰写过程中给予的耐心指导和建议,使我在科研能力和学术素养上得到了全面的提升。

感谢实验室的各位同学在实验过程中提供的帮助,以及在日常学习和生活中给予的关心和支持。

最后,感谢家人和朋友们的理解与鼓励,你们的支持是我前进的最大动力。

卫祎懿

上海大学

2026年05月11日

